

O uso de Aprendizado de Máquina na Predição de Acidente Vascular Cerebral (AVC)

Graziela Silva Araújo

Universidade Federal de Viçosa - UFV
Disciplina: Engenharia de Aprendizado de Máquina (CCF 726)
Professor: Fabrício Silva

Resumo

O aprendizado de máquina (ML) oferece bons resultados para previsão rápida e precisa, desta forma, tem ganhado espaço no ambiente de saúde. No entanto, mesmo que para alguns campos de pesquisa tenham recebido atenção adequada, ainda exista a necessidade de explorar seu uso em algumas áreas da saúde. Neste trabalho é realizada uma discussão referente a abordagens que aplicam o ML, disponíveis na literatura, que propõem métodos para previsão de AVC. Ainda, demonstra os resultados referente aos experimentos realizados.

1. Introdução

No Brasil, o Acidente Vascular Cerebral (AVC) ocupa o segundo lugar como causa de óbitos e representa cerca de 10% de todas as hospitalizações (Ferraz 2021). O AVC é uma emergência médica caracterizada por danos às células cerebrais devido à interrupção do suprimento sanguíneo para o cérebro, seja por obstrução dos vasos sanguíneos (AVC isquêmico) ou por ruptura dos mesmos (AVC hemorrágico) (Gov. 2023). A Figura 2, mostra os dois principais tipos de AVC, o (A) (AVC isquêmico) que ocorre quando um vaso sanguíneo que alimenta o cérebro é bloqueado por um coágulo de sangue, restringindo o fluxo sanguíneo para uma determinada área, e (B) (AVC hemorrágico) que ocorre quando um vaso sanguíneo se rompe, resultando em sangramento no cérebro.

O impacto negativo do AVC na sociedade levou a esforços concentrados para melhorar o diagnóstico do AVC. (Gov. 2023). O diagnóstico rápido e preciso do AVC desempenha um papel crucial na determinação do tratamento adequado e na melhoria dos resultados clínicos Cancela (2008). Nesse contexto, considerando avanços significativos na compreensão, prevenção e tratamento do AVC, o uso do aprendizado de máquina tem ganhado destaque como uma abordagem promissora para auxiliar no diagnóstico precoce e preciso do AVC Herzog *et al.* (2020).

O aprendizado de máquina é uma área da inteligência artificial que se concentra no desenvolvimento de algoritmos e modelos capazes de aprender a partir de dados, identificar padrões complexos e tomar decisões com base nesse conhecimento (Herzog *et al.* 2020). Quando aplicado ao diagnóstico do AVC, o aprendizado de máquina permite a análise de uma ampla variedade de dados clínicos, como sinais vitais, exames de imagem, histórico médico e fatores de risco, a fim de identificar indicadores e padrões que possam indicar a ocorrência de um AVC (Hung *et al.* 2017).

O objetivo desta revisão é investigar a aplicação do aprendizado de máquina no diagnóstico do AVC. Serão examinados estudos recentes que utilizaram técnicas de aprendizado de máquina, incluindo classificação, regressão e redes neurais, com o objetivo de desenvolver modelos de diagnóstico e previsão do AVC. Adicionalmente, serão analisadas




FIGURA 1. Tipos principais de AVC: (A) o AVC isquêmico (AVCI) e (B) o AVC hemorrágico (AVCH)

as vantagens, limitações e desafios relacionados à aplicação do aprendizado de máquina nesse contexto específico.

É de extrema importância reconhecer o potencial do aprendizado de máquina no diagnóstico do AVC, pois isso contribui para a melhoria da precisão e eficiência do diagnóstico clínico (Ferreira 2018). Além disso, essa abordagem tem a capacidade de auxiliar os médicos na tomada de decisões, permitindo a identificação dos pacientes com maior risco de AVC e a implementação de intervenções preventivas e terapêuticas adequadas.

Ao final desta revisão, espera-se fornecer uma visão geral abrangente do estado atual da pesquisa sobre o uso do aprendizado de máquina no diagnóstico do AVC. Compreender e explorar as possibilidades do aprendizado de máquina pode impulsionar avanços significativos no diagnóstico e tratamento do AVC, contribuindo para melhorar os resultados clínicos e a qualidade de vida dos pacientes afetados por essa condição grave.

2. Aprendizado de máquina na previsão do AVC

O aprendizado de máquina (ML) é um campo da inteligência artificial que se concentra no desenvolvimento de algoritmos e modelos capazes de aprender a partir de dados e fazer previsões ou tomar decisões. Algoritmos de ML foram empregados para auxiliar em diagnóstico (Tajdini & Mehri 2022). Seu uso abrange uma ampla gama de aplicações, incluindo detecção precoce de diagnósticos em imagens, estimativa do tempo de início do AVC, segmentação da lesão e do tecido afetado, análise do edema cerebral, bem como a previsão de complicações e resultados dos pacientes após o tratamento (Takahashi *et al.* 2014; Tajdini & Mehri 2022; Chen *et al.* 2017).

Com o uso do aprendizado de máquina, a capacidade de identificar, tratar, prognosticar e até antecipar doenças usando dados clínicos melhorou significativamente, pois os modelos de ML podem analisar uma variedade de dados clínicos, como histórico médico, exames de imagem, dados de sinais vitais e fatores de risco, para identificar padrões e relacionamentos complexos. (Tajdini & Mehri 2022). À medida que os médicos adquirem maior confiança nas técnicas de aprendizado de máquina (ML), espera-se que sua aplicação cresça em diversas especialidades médicas (Bydon *et al.* 2020).

De forma prática, os modelos preditivos são capazes de identificar pessoas com risco de AVC com base em dados pessoais e fatores de risco específicos. Esses modelos têm o potencial de serem empregados em triagens em larga escala, possibilitando a identificação daqueles que poderiam se beneficiar de intervenções preventivas.

Apesar dos avanços promissores, alguns desafios precisam ser superados para a implementação bem-sucedida do aprendizado de máquina na previsão do AVC. A disponibilidade de conjuntos de dados de alta qualidade e de tamanho adequado é fundamental para treinar e validar os modelos de aprendizado de máquina. Desta forma, é preciso lidar com questões éticas e de privacidade dos dados por conter informações sensíveis de saúde. Além disso, é importante garantir a interpretabilidade dos modelos, para que os médicos possam entender as razões por trás das previsões e tomar decisões clínicas embasadas (Tajdini & Mehri 2022).

3. Revisão da literatura

Diversos estudos têm explorado o grande potencial do ML para diagnósticos e previsão de AVC. Esses estudos utilizam uma grande variedade de algoritmos, afim de analisar grandes conjuntos de dados clínicos e identificar padrões complexos associados ao AVC. Os trabalhos presentes na literatura têm investigado vários aspectos da previsão de AVC (Dev *et al.* 2022). Como Hung *et al.* (2017), que utiliza um grande conjunto de dados *Electronic medical claims - EMC* de base populacional de cerca de 800.000 pacientes para comparar a rede neural profunda (DNN) com três outras abordagens de ML (árvore de decisão (DT), regressão logística (LR) e máquina de vetor de suporte-SVM) para prever a ocorrência de AVC em 5 anos. Os autores concluem que a DNN alcançou resultados ideais usando quantidades menores de dados de pacientes.

Dev *et al.* (2022) analisa sistematicamente vários fatores nos registros eletrônicos de saúde para uma previsão eficaz de AVC. Utiliza várias técnicas estatísticas e análise de componentes principais, para identificar os fatores mais importantes para a previsão de AVC. E concluem que, idade, doenças cardíacas, nível médio de glicose e hipertensão são os fatores mais importantes para a detecção de AVC em pacientes. Devido ao fato do conjunto de dados serem altamente desequilibrado em relação à ocorrência de acidente vascular cerebral, os autores relatam seus resultados em um conjunto de dados balanceado criado através de técnicas de sub-amostragem.

Shanthi *et al.* (2009), investigaram o uso de Redes Neurais Artificiais (ANN) na previsão da doença tromboembólica do AVC, afim de demonstrar que a previsão baseada em ANN melhora a acurácia do diagnóstico. Herzog *et al.* (2020) fornece uma estrutura completa para diagnosticar pacientes com AVC isquêmico incorporando a incerteza Bayesiana no procedimento de análise. Apresenta uma Rede Neural Bayesiana Convolutiva (CNN) produzindo uma probabilidade para uma lesão de AVC em imagens de Ressonância Magnética (RM) 2D.

Em Chen *et al.* (2017) propõem uma nova estrutura para segmentar automaticamente as lesões do AVC. Apresenta um *framework* que consiste em duas redes neurais convolucionais (CNNs): uma é um conjunto de duas DeconvNets, e a segunda CNN é a rede de avaliação de rótulos convolucionais em multiescala. Segundo os autores, sua contribuição é a primeira tentativa de se resolver o problema. Sua abordagem é avaliada em um grande conjunto de dados composto por imagens de DW adquiridas clinicamente de 741 indivíduos.

Trabalho como Yoo *et al.* (2012), demonstram que identificar características importantes impactam no desempenho do *framework* de aprendizado de máquina. E discute sobre a importância de identificar a melhor combinação de atributos, ao em vez de utilizar todos os atributos disponíveis. Os autores indicam que atributos identificados como irrelevantes devem ser removidos.

Por fim, Jeena & Kumar (2016), investiga parâmetros fisiológicos que são utilizados

como fatores de risco para a predição do AVC. Utilizam dados coletados de um banco de dados International Stroke Trial para avaliar o SVM com diferentes funções de *kernel*.

4. Método

4.1. Implementação

Para a realização deste trabalho, foram utilizados a plataforma Kaggle para buscar a banco de dados utilizado para avaliar o modelo; o google colab, para codificação; a Azure para testes com bibliotecas; Hunngging Face para realizar o deploy da demo do modelo; e a biblioteca Gradio, para criar interface para interação com o modelo.

4.2. Banco de Dados

O banco de dados utilizado é um conjunto que contém 40.910 amostras de pacientes, que foram disponibilizada de forma pública. O objetivo seria prever acidente vascular cerebral (AVC) de acordo com dados dos pacientes. O conjunto de dados foi disponibilizado limpo, aumentado e com classes balanceadas. Entre seus dados só possui valores do tipo **int** e **float**. Para melhor avaliação dos métodos, a base de dados foi dividida separando-se 70% das amostras para o treino e 30% das amostras para teste.

4.3. Análise de correlação

Para análise dos dados, foi utilizado o coeficiente de correlação de *Pearson*. Este coeficiente de correlação de Pearson é um teste que mede a relação estatística entre duas variáveis contínuas. Se a associação entre os elementos não for linear, o coeficiente não será representado adequadamente. O coeficiente de correlação de *Pearson* pode ter um intervalo de valores de +1 a -1. Um valor de 0 indica que não há associação entre as duas variáveis. Um valor maior que 0 indica uma associação positiva. Isto é, à medida que o valor de uma variável aumenta, o mesmo acontece com o valor da outra variável. Um valor menor que 0 indica uma associação negativa. Isto é, à medida que o valor de uma variável aumenta, o valor da outra diminui. A correlação pode ser vista na figura abaixo:

4.4. Análise de Componente Principal (PCA)

A análise de Componente principal (PCA) é uma técnica estatística amplamente utilizada para análise de dados multivariados. O PCA é uma ferramenta poderosa que permite reduzir a complexidade de conjuntos de dados, identificando e destacando as principais estruturas subjacentes aos mesmos.

A ideia fundamental do PCA é encontrar uma representação de menor dimensão dos dados originais, mantendo a maior parte da informação relevante contida nos mesmos. Para fazer isso, o PCA procura combinações lineares dos atributos originais que expliquem a maior quantidade possível de variância nos dados.

Através da redução de dimensionalidade realizada pelo PCA, é possível visualizar e interpretar os dados de maneira mais eficiente. No entanto, para o problema em questão, não a partir dos experimentos foi constatado que os componentes principais são necessários para obter um melhor resultado.

4.5. Previsão do AVC

Afim de analisar a performance de diferentes algoritmos, foram realizados diferentes experimentos, com os seguintes métodos:

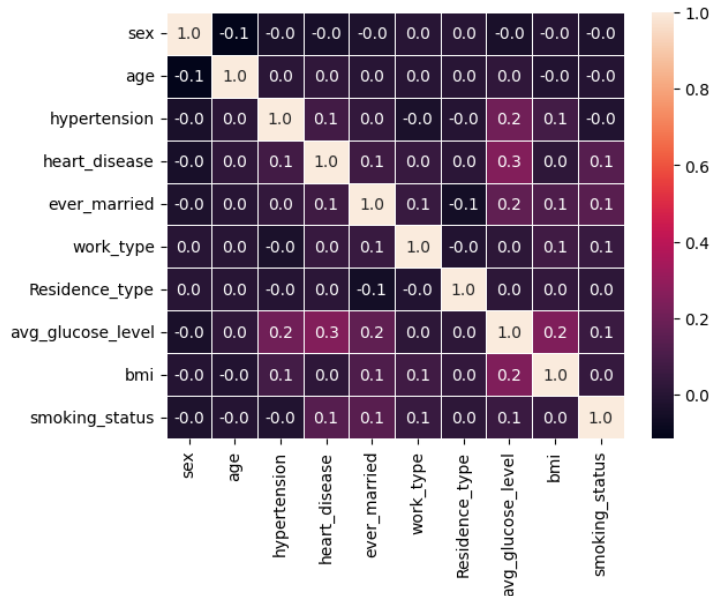


FIGURA 2. Correlação utilizando coeficiente de Pearson.

- Árvore de decisão;
- Random Forest;
- XGBoost.

Ambos os métodos foram testados aplicando o PCA e sem PCA. Entre os modelos testados, o XGBoost foi o que alcançou o melhor resultado. Extreme Gradient Boosting (XGBoost), é um algoritmo de aprendizado de máquina baseado em árvores de decisão que se destaca por sua eficiência e desempenho excepcionais em uma ampla gama de problemas de modelagem preditiva. Além de oferecer recursos avançados, como regularização, que ajuda a evitar a *overfitting* (sobreajuste) do modelo, e manipulação de valores ausentes, permitindo que ele lide com dados incompletos de forma robusta.

O desempenho do XGBoost é frequentemente reconhecido em competições de ciência de dados e machine learning, e muitos o consideram um dos algoritmos mais poderosos disponíveis. Por fim, o XGBoost cria modelos preditivos de alta precisão. Sua capacidade de lidar com grandes volumes de dados, variáveis preditoras e sua eficiência o tornam uma escolha popular entre os cientistas de dados e praticantes de machine learning.

5. Discussão

Existem várias questões a serem avaliadas antes que técnicas de ML possam ser empregada na prática clínica. O ML é uma abordagem em que a máquina é capaz de aprender de acordo com os dados informados. No entanto, por trás dessa processo existe mecanismos técnicos e lógicos altamente complexos e difíceis de serem compreendidos. Esta característica vem em conflito com o conceito da medicina baseada em evidência (Lee Eun-Jae 2017).

A falta de compreensão relacionado ao funcionamento interno da ML pode-se levar a questões éticas e legais, afinal, de quem é a responsabilidade pelas decisões tomadas pelo modelo na prática clínica do mundo real. Um outro ponto a ser observado é referente ao subajuste, em que o modelo funciona bem nos dados utilizados para o treino, mas não

Autor	Método	Acurácia (%)	Método	Acurácia (%)
Kumar et. al.(2016)	SVM	90	DT	0.83
Liu et. al. (2019)	RF	71	RF	0.81
Badesa, et al. (2014)	SVM	91.43	XGBoost	0.99
<i>Este trabalho</i>	XGBoost	0.99	XGBoost (PCA)	0.74

FIGURA 3. Comparação entre os métodos abordados e os trabalhos da literatura.

é aplicável para outros dados. Portanto, é fundamental verificar a capacidade do modelo de generalizar para diferentes conjuntos de dados e ainda examinar sua robustez diante de diversos cenários.

Na Figura. 3, mostra uma comparação realizada entre os métodos presentes na literatura e os métodos aplicados. Pode-se perceber que o XGboost possui um resultado superior ao demais métodos. Tanto, os métodos presentes na literatua quanto os métodos avaliados neste trabalho, como: Ávore de decisão (DT), random Forest (RF).

6. Conclusão

Neste trabalho foi realizada uma discussão referente a trabalhos já publicados que utilizaram abordagens de ML para previsão de AVC. Conclui-se que, o uso do aprendizado de máquina na previsão de AVC apresenta um grande potencial para melhorar a detecção precoce e a tomada de decisões clínicas. Os modelos de aprendizado de máquina podem analisar uma ampla variedade de dados clínicos, incluindo fatores de risco, informações médicas e imagens, para identificar indivíduos em risco de AVC.

Apesar dos desafios, o uso do aprendizado de máquina na previsão de AVC pode trazer benefícios significativos para a saúde pública, permitindo uma identificação mais rápida e precisa dos indivíduos em risco e a implementação de intervenções preventivas adequadas.

Contudo, o XGBoost sem aplicação do PCA, alcançou 99% de acurácia, sendo superior aos demais métodos. Enfim, é essencial continuar a investir em pesquisas e desenvolvimento nessa área, aproveitando todo o potencial do ML para a previsão de AVC e buscando soluções que sejam clinicamente relevantes, eticamente sólidas e capazes de serem integradas à prática médica de rotina. Com esforços contínuos, podemos esperar avanços significativos na prevenção e tratamento do AVC, melhorando a saúde e o bem-estar das pessoas afetadas por essa doença.

REFERENCES

- BYDON, MOHAMAD, SCHIRMER, CLEMENS M, OERMANN, ERIC K, KITAGAWA, RYAN S, POURATIAN, NADER, DAVIES, JASON, SHARAN, ASHWINI & CHAMBLESS, LOLA B 2020 Big data defined: a practical review for neurosurgeons. *World neurosurgery* **133**, e842–e849.
- CANCELA, DIANA MANUELA GOMES 2008 O acidente vascular cerebral: classificação, principais consequências e reabilitação. *Porto: ULP* pp. 494–498.
- CHEN, LIANG, BENTLEY, PAUL & RUECKERT, DANIEL 2017 Fully automatic acute ischemic lesion segmentation in dwi using convolutional neural networks. *NeuroImage: Clinical* **15**, 633–643.
- DEV, SOUMYABRATA, WANG, HEWEI, NWOSU, CHIDOZIE SHAMROCK, JAIN, NISHTHA, VEERAVALLI, BHARADWAJ & JOHN, DEEPU 2022 A predictive analytics approach for stroke prediction using machine learning and neural networks. *Healthcare Analytics* **2**, 100032.
- FERRAZ, MARIA ELISABETH MATTA DE REZENDE 2021 Você sabe o que é AVC? <https://sp.unifesp.br/epm/noticias/voce-sabe-o-que-e-avc>.
- FERREIRA, TÂNIA DANIELA GONÇALVES 2018 Hipertensão arterial: Fatores de adesão terapêutica e intervenções benéficas. PhD thesis.
- GOV. 2023 Acidente vascular cerebral. url<https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/a/avc>.
- HERZOG, LISA, MURINA, ELVIS, DÜRR, OLIVER, WEGENER, SUSANNE & SICK, BEATE 2020 Integrating uncertainty in deep neural networks for mri based stroke analysis. *Medical image analysis* **65**, 101790.
- HUNG, CHEN-YING, CHEN, WEI-CHEN, LAI, PO-TSUN, LIN, CHING-HENG & LEE, CHI-CHUN 2017 Comparing deep neural network and other machine learning algorithms for stroke prediction in a large-scale population-based electronic medical claims database. In *2017 39th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 3110–3113.
- JEENA, R S & KUMAR, SUKESH 2016 Stroke prediction using svm. In *2016 International Conference on Control, Instrumentation, Communication and Computational Technologies (ICCICCT)*, pp. 600–602.
- LEE EUN-JAE, KIM YONG-HWAN, KIM NAMKUG KANG DONG-WHA 2017 Deep into the brain: Artificial intelligence in stroke imaging. *J Stroke* **19** (3), 277–285, arXiv: <http://www.j-stroke.org/journal/view.php?number=198>.
- SHANTHI, D, SAHOO, G & SARAVANAN, N 2009 Designing an artificial neural network model for the prediction of thrombo-embolic stroke. *International Journals of Biometric and Bioinformatics (IJBB)* **3** (1), 10–18.
- TAJDINI, FARZANE & MEHRI, RAZIYE 2022 Machine learning for brain stroke: A review.
- TAKAHASHI, NORIYUKI, LEE, YONGBUM, TSAI, DU-YIH, MATSUYAMA, ERI, KINOSHITA, TOSHIBUMI & ISHII, KIYOSHI 2014 An automated detection method for the mca dot sign of acute stroke in unenhanced ct. *Radiological physics and technology* **7**, 79–88.
- YOO, ILLHOI, ALAFAIREET, PATRICIA, MARINOV, MIROSLAV, PENA-HERNANDEZ, KEILA, GOPIDI, RAJITHA, CHANG, JIA-FU & HUA, LEI 2012 Data mining in healthcare and biomedicine: a survey of the literature. *Journal of medical systems* **36**, 2431–2448.